Modelagem de Risco de Crédito

Avaliação de Inadimplência com Random Forest & Análise Crítica de Métricas

Aluno: Pedro Henrique Nunes Zanette
Curso: Bacharelado em Ciência de Dados e Inteligência Artificial
Unidade Curricular: Engenharia de Dados e MLOps
Professor: Prof. MSc. Hugo Menezes Barra
Atividade: Modelos de Machine Learning — Risco de Crédito
Repositório GitHub: https://github.com/PedroZanette/trabalho-ml-risco-credito-mlops

Todos os valores abaixo foram gerados pela execução de `risco_credito.py` (semente 42, scikit-learn 1.9.1), com base sintética de 2.000 clientes e divisão estratificada 80/20 (1.600 treino / 400 teste).

Parte 1 — Modelo Base

A base foi gerada com o código fornecido (RendaMensal, ScoreCredito, EmprestimosAtivos) e o RandomForestClassifier foi treinado com os parâmetros estipulados (200 árvores, max_depth=8, max_features='sqrt', oob_score=True).

Métrica	Valor
Acurácia OOB (treino)	0,9344
ROC-AUC (teste)	0,8566

Parte 2 — Interpretabilidade e Importância das Variáveis

3. As importâncias foram extraídas de `modelo_rf.feature_importances_` e ordenadas de forma decrescente. Como complemento, foi calculada a Permutation Importance no conjunto de teste, que mede quanto a ROC-AUC cai quando cada variável é embaralhada.

Variável	Importância Gini	Permutation (Δ ROC-AUC)
RendaMensal	**0,4121**	**0,1196**
ScoreCredito	0,3555	0,1150
EmprestimosAtivos	0,2324	0,1040

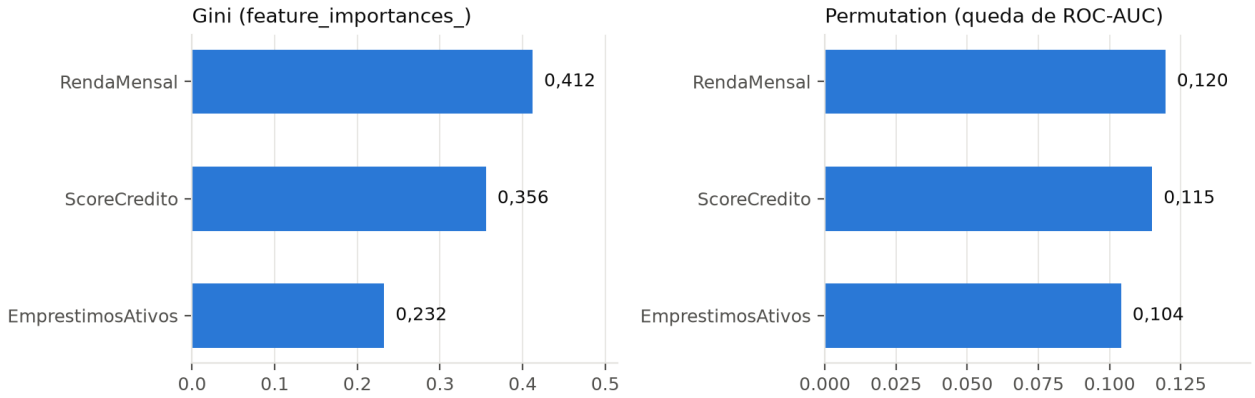


Figura 1 — Importância das variáveis pelos dois métodos.

4. Qual variável foi o fator de maior impacto?

A **RendaMensal**, com 41,2% da importância Gini total, seguida de ScoreCredito (35,6%) e EmprestimosAtivos (23,2%). A Permutation Importance confirma a mesma ordem, embora com diferenças menores entre as três variáveis — ou seja, todas contribuem de forma relevante. O resultado é coerente com a função que gerou os dados: o coeficiente da renda (–0,0003) multiplicado pela sua alta

variabilidade (desvio-padrão ≈ 5.000) produz o maior efeito sobre a probabilidade de inadimplência; quanto menor a renda, maior o risco. Vale notar que a importância Gini tende a favorecer variáveis contínuas com muitos valores distintos, por isso a verificação por permutação é recomendada.

Parte 3 — Análise Crítica e Desbalanceamento de Classes

5. Proporção de inadimplentes na base completa

135 de 2.000 clientes = 6,75% são inadimplentes; 93,25% são adimplentes. A base é fortemente desbalanceada.

6. Matriz de Confusão e Relatório de Classificação (teste, threshold 0,5)

	Previsto adimplente (0)	Previsto inadimplente (1)
Real adimplente (0)	370	3
Real inadimplente (1)	25	2

Classe	Precision	Recall	F1-score	Suporte
0 — adimplente	0,9367	0,9920	0,9635	373
1 — inadimplente	**0,4000**	**0,0741**	**0,1250**	**27**
Média macro	0,6684	0,5330	0,5443	400
Média ponderada	0,9005	0,9300	0,9069	400
Acurácia			0,9300	400

7. Reflexão Crítica — a acurácia OOB de 93,4% é confiável?

Não. Como 93,25% dos clientes são adimplentes, um modelo trivial que respondesse *sempre* "não vai inadimplir" teria acurácia de 93,25% no teste — praticamente igual à acurácia OOB do Random Forest (93,44%) e superior à acurácia obtida no teste (93,00%). A acurácia alta reflete o desbalanceamento, não a capacidade do modelo de identificar o risco.

A matriz de confusão confirma: dos 27 inadimplentes do teste, o modelo detectou apenas **2** (recall de 7,4%) e deixou passar **25**. Para a fintech, cada falso negativo é crédito concedido a quem não vai pagar — exatamente o prejuízo que o modelo deveria evitar. O risco de usar a acurácia como métrica principal é aprovar um modelo que parece excelente no papel, mas que na prática não cumpre o objetivo de negócio.

Métricas mais adequadas para este cenário são **Recall, Precision e F1 da classe 1**, a curva Precision-Recall e a **ROC-AUC**. A ROC-AUC de 0,857 mostra que o modelo *ordena* bem os clientes por risco; o problema está no threshold padrão de 0,5, inadequado para uma classe minoritária de 6,75%.

Parte 4 — Desafio Extra: class_weight='balanced' e ajuste de threshold

Foi treinado um segundo modelo com os mesmos hiperparâmetros e `class_weight='balanced'`, que atribui peso maior aos inadimplentes durante o treino. Os dois modelos foram avaliados em quatro thresholds de decisão.

Modelo	Threshold	Recall classe 1	Detectados (TP)	Perdidos (FN)	Falsos alarmes (FP)
Original	0,50	7%	2	25	3
Original	0,30	26%	7	20	13
Original	0,20	56%	15	12	27
Original	0,10	70%	19	8	63
Balanced	**0,50**	**70%**	**19**	**8**	**52**
Balanced	0,30	81%	22	5	88
Balanced	0,20	81%	22	5	108
Balanced	0,10	93%	25	2	154

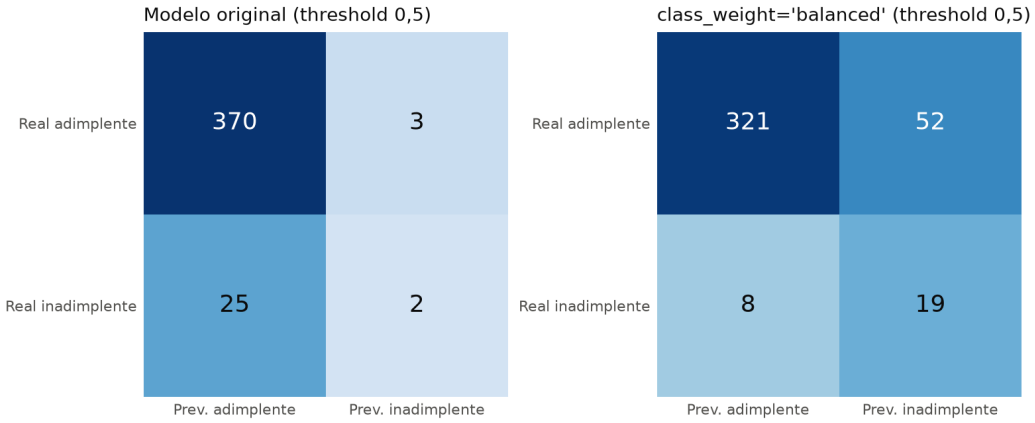


Figura 2 — Matrizes de confusão no teste, threshold 0,5 (cor em escala logarítmica).

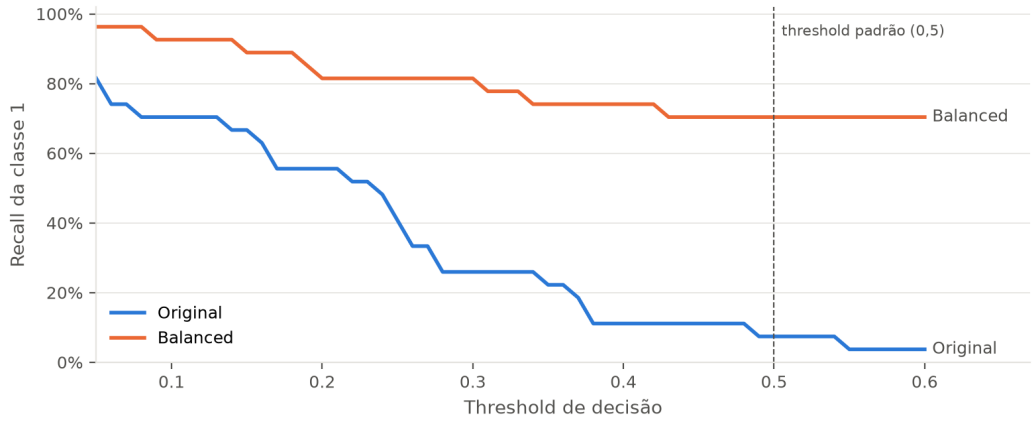


Figura 3 — Recall da classe 1 em função do threshold de decisão.

8. Impacto na taxa de detecção dos inadimplentes (Recall da classe 1)

• Apenas com **class_weight='balanced'** (threshold 0,5), o recall da classe 1 sobe de **7% para 70%**: o modelo passa a detectar 19 dos 27 inadimplentes, em vez de 2.
• **Reduzir o threshold** tem efeito semelhante: no modelo original, baixar para 0,10 também leva o recall a 70%. Combinando as duas técnicas, chega a **93%** (balanced, threshold 0,10).
• O ganho tem custo: os **falsos alarmes aumentam** (de 3 para 52 no balanced 0,5, e até 154 no

threshold 0,10), ou seja, bons clientes seriam recusados ou enviados para análise manual.
• A ROC-AUC praticamente não muda (0,857 → 0,861): o modelo não ficou melhor em *separar* as classes; o que mudou foi o ponto de corte da decisão.

Conclusão

A escolha do threshold é uma decisão de negócio, não apenas técnica. Se o custo de um calote é muito maior que o de recusar um bom cliente — o caso típico em crédito — vale priorizar o recall da classe 1 (por exemplo, modelo balanced com threshold entre 0,3 e 0,5), aceitando mais análises manuais. O ideal é definir o limiar a partir do custo real de cada tipo de erro.

Observação metodológica: neste trabalho os thresholds foram comparados diretamente no conjunto de teste, para fins de análise. Em um pipeline de produção, o limiar deveria ser escolhido em um conjunto de validação (ou por validação cruzada / predições OOB) e o teste usado apenas uma vez, para a estimativa final de desempenho — evitando um resultado otimista.